

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет об исследовательском проекте на тему:

**«Анализ и визуализация данных с использованием Yandex
DataLens: исследование по прогнозированию CTR»**

Выполнил:

студент группы БПМИ-247

Грицан Максим Андреевич

(дата)

Принял руководитель проекта:

Иванов Андрей Александрович

Доцент, Базовая кафедра Т-Банка

Факультета компьютерных наук НИУ ВШЭ

Москва 2026

Аннотация

Данная курсовая работа посвящена исследованию методов анализа и визуализации данных в контексте задачи прогнозирования кликабельности (CTR) рекламных объявлений.

В качестве основного инструмента визуализации использовалась платформа Yandex DataLens. В работе описан полный цикл обработки данных с применением методов машинного обучения.

Результатом работы стала разработка интерактивного дашборда, позволяющего проводить мониторинг динамики CTR, анализировать эффективность рекламных кампаний в различных срезах и наглядно интерпретировать результаты прогнозирования. В исследовании продемонстрирована практическая применимость Yandex DataLens для задач бизнес-аналитики и оценки качества моделей машинного обучения.

Ключевые слова: CTR, интернет реклама, Yandex DataLens, визуализация данных, бизнес-аналитика, дашборд, CatBoost.

Содержание

1 Основные термины и определения	4
2 Введение	7
2.1 Цель исследования	10
2.2 Объект исследования	10
2.3 Предмет исследования	10
2.4 Методы исследования	10
2.5 Задачи исследования	10
2.6 Актуальность работы	11
2.7 План работы	11
2.7.1 Графическое представление плана работы	12
3 Описание набора данных Click-Through Rate Prediction . .	14
3.1 Общая характеристика набора данных	14
3.2 Описание полей набора данных	14
3.2.1 Распределение категорий сайтов	15
3.2.2 Распределение категорий приложений	16
3.3 Временная динамика показов и кликов	17
3.4 Пример данных	18
3.5 Особенности набора данных	20
3.5.1 Анонимизация данных	20
3.5.2 Дисбаланс классов	20
3.6 Применение набора данных	20
4 Обзор академических источников	21
5 Проектирование и разработка макета интерактивного дашборда	23
5.1 Концепция и архитектура дашборда	23
5.2 Продуктовые показатели рекламы и бизнес-метрики	24
5.3 Разведочный анализ данных (EDA) и структура набора данных	27
5.4 Оценка модели CatBoost и важность признаков	29
6 Обучение модели CatBoost для предсказания CTR	33
6.1 Подготовка данных для обучения модели	33
6.2 Выбор платформы для обучения модели	34
6.3 Обучение модели CatBoost	34
6.4 Итоговые показатели модели на валидационной и тестовой выборках	36
7 Подготовка и загрузка данных для дашборда	37

7.1	Подготовка ClickHouse и загрузка данных	38
7.2	Извлечение необходимых метрик и сводных данных из модели CatBoost	39
7.2.1	Базовые метрики на валидационной выборке	39
7.2.2	Данные для чартов из Lift блока	40
7.2.3	Полезность признаков	41
7.2.4	Качество влияния на целевую связок признаков	42
7.2.5	Предсказанный CTR в сравнении с реальным в срезах разных признаков	42
7.2.6	Данные для диаграммы надежности модели	42
7.3	Подключение источников данных в Yandex DataLens	43
7.3.1	Подключение ClickHouse	43
7.3.2	Подключение метрик и сводных таблиц из модели CatBoost	44
7.4	Создание датасетов в Yandex DataLens	44
8	Заключение	45
8.1	Описание выполненных задач	45
8.2	Описание структуры Git репозитория	46
8.3	Описание интерактивной визуализации	46
8.4	Ответ на основной вопрос работы	47
8.5	Ограничения работы	47
8.6	Развитие работы	48
9	Описание применения генеративной модели	49
9.1	Верстка отчета для курсовой работы на языке Typst	49
9.2	Изучение возможностей библиотеки CatBoost	49
	Список литературы	50

1 Основные термины и определения

1. **CTR** – метрика в интернет-маркетинге. CTR определяется как отношение числа кликов на баннер или рекламное объявление к числу показов, измеряется в процентах [1].
2. **Yandex DataLens** – сервис для бизнес-аналитики. Сервис позволяет подключаться к различным источникам данных, строить визуализации, собирать дашборды, отчеты и презентации, а также делиться полученными результатами [2].
3. **Разведочный анализ данных (EDA)** – анализ основных свойств данных, нахождение в них общих закономерностей, распределений и аномалий, построение начальных моделей, зачастую с использованием инструментов визуализации [3].
4. **Kaggle** – система организации конкурсов по исследованию данных, а также социальная сеть специалистов по обработке данных и машинному обучению. Среда организована как публичная веб-платформа, на которой пользователи и организации могут публиковать наборы данных, исследовать и создавать модели, взаимодействовать с другими специалистами по данным и инженерами по машинному обучению, организовывать конкурсы по исследованию данных и участвовать в них [4].
5. **CatBoost** – это высокопроизводительная библиотека с открытым исходным кодом для градиентного бустинга на деревьях решений [5].
6. **Диаграмма** – графическое представление данных линейными отрезками или геометрическими фигурами, позволяющее быстро оценить соотношение нескольких величин [6].
7. **Дашборд** – это графический отчет из различных данных, относящихся к конкретной теме, бизнесу. Дашборд генерирует информацию, которая позволяет пользователям отслеживать тенденции, выявлять аномалии и углубляться в специфику. Он служит инструментом для мониторинга и принятия решений, экономит время, необходимое для сбора и оформления данных [7].
8. **Чарт** – это визуализация данных из набора данных в виде таблицы, диаграммы или картограммы [8].
9. **Виджет** – это элемент дашборда. Например, чарт или селектор [9].

10. **Селектор** – это фильтр, который влияет на результаты запросов на связанных с ним виджетах (в Yandex DataLens) [10].
11. **LogLoss** – функция потерь для задач классификации в машинном обучении. Она задается формулой:

$$L(w, X, y) = \sum_{i=1}^N \log(1 + e^{-y_i \langle w, x_i \rangle}),$$

где X – множество объектов, y – целевая переменная, N – количество объектов и w – веса модели [11].

12. **ROC-AUC** – метрика классификации в машинном обучении, которая равна площади под ROC кривой (англ. receiver operating characteristics curve) или доле пар объектов вида (объект класса 1, объект класса 0), которые алгоритм верно упорядочил, то есть предсказание классификатора на первом объекте больше:

$$\text{ROC-AUC} = \frac{\sum_{i=1}^N \sum_{j=1}^N \mathbb{I}[y_i < y_j] \mathbb{I}'[f(x_i) < f(x_j)]}{\sum_{i=1}^N \sum_{j=1}^N \mathbb{I}[y_i < y_j]},$$

$$\mathbb{I}'[f(x_i) < f(x_j)] = \begin{cases} 0, & f(x_i) > f(x_j) \\ 0,5, & f(x_i) = f(x_j) \\ 1, & f(x_i) < f(x_j) \end{cases}$$

$$\mathbb{I}[y_i < y_j] = \begin{cases} 0, & y_i \geq y_j \\ 1, & y_i < y_j \end{cases}$$

где x_i – i -й объект, y_i – класс i -го объекта, а $f(x)$ – классификатор [12].

13. **Accuracy** – метрика классификации в машинном обучении, которая равна доле объектов, для которых модель правильно предсказали класс:

$$\text{Accuracy}(y, y^{\text{pred}}) = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[y_i = y_i^{\text{pred}}],$$

где y_i – настоящий класс i -го объекта, а y_i^{pred} – предсказанный класс i -го объекта [12].

14. **ClickHouse** – колоночная аналитическая СУБД с открытым кодом, позволяющая выполнять аналитические запросы в режиме реального времени на структурированных больших данных. Также одноименна компания, предоставляющая облачную инфраструктуру для баз данных [13].
15. **Jupyter Notebook** – интерактивный блокнот, в котором можно выполнять код на разных языках программирования, добавлять к нему текст, изображения, инфографику и формулы. Его главная особенность в том, что пользователь сразу видит код и результат его работы, а фрагменты кода можно запускать по частям [14].

2 Введение

В условиях стремительной цифровизации мировой экономики интернет-реклама стала одним из наиболее эффективных и высокотехнологичных инструментов продвижения товаров и услуг. Ежедневно миллионы пользователей взаимодействуют с рекламными объявлениями, и понимание факторов, влияющих на их поведение, является критически важным для эффективного распределения рекламных бюджетов.

Одной из ключевых метрик эффективности интернет-рекламы является CTR (Click-Through Rate) – показатель кликабельности, определяющий отношение числа кликов на рекламное объявление к числу его показов. Прогнозирование CTR позволяет оптимизировать рекламные кампании, повысить их эффективность и снизить затраты на привлечение клиентов.

Современный рынок мобильной рекламы функционирует на базе аукционов реального времени (RTB), где за доли секунды принимается решение о показе конкретного рекламного баннера конкретному пользователю. Для этого необходимо проводить качественный разведочный анализ данных (EDA). Этот этап помогает найти закономерности, выбросы и особенности распределения данных. На основе такого анализа можно лучше подготовить данные и построить модель для прогнозирования CTR.

В рамках данной курсовой работы проводится исследование набора данных «Avazu Click-Through Rate Prediction», изначально представленного в качестве соревновательного набора данных на платформе Kaggle. Данный массив представляет собой большое количество логов мобильной рекламы, собранное в течение 10 дней. Набор данных насчитывает более 40 миллионов уникальных записей и содержит анонимизированную с помощью хеширования информацию о каждом показе: характеристики рекламных баннеров, технические параметры мобильных устройств (тип, модель, способ подключения к сети), а также категории веб-сайтов и приложений, где происходил показ. Наличие бинарной целевой переменной в условиях естественного дисбаланса классов: около 17% кликов и 83% безрезультативных показов. Такой дисбаланс делает набор данных «Avazu Click-Through Rate Prediction» репрезентативным для реальных задач интернет-маркетинга.

Этот набор данных широко признан в индустрии и академической среде в качестве стандартизированного бенчмарка и валидатора для раз-

рабатываемых моделей машинного обучения. Он регулярно применяется для комплексного бенчмаркинга наряду с другими индустриальными стандартами (например, Criteo). Это позволяет набору данных от Avazu представлять надежную, стандартизированную основу для объективного сравнения эффективности новых алгоритмов прогнозирования CTR с уже существующими решениями. Это делает результаты тестирования и оценки метрик значимыми для бизнес-решений и индустрии, оптимизирующие рекомендательные системы и рекламные аукционы.

Набор данных Avazu часто используется как в индустрии, так и в исследовательских работах в качестве бенчмарка для проверки моделей машинного обучения. Его часто используют наравне с другими известными рекламными наборами данных, например Criteo, при тестировании алгоритмов прогнозирования CTR. Благодаря этому можно объективно оценивать качество новых подходов и сравнивать их с уже существующими решениями. Результаты таких экспериментов имеют практическую ценность для задач, связанных с рекомендательными системами и рекламными аукционами.

Основным инструментом для решения задачи предсказания вероятности клика пользователя по рекламному объявлению в работе стал алгоритм CatBoost. Это библиотека для языка программирования Python, в основе которой лежит архитектура градиентного бустинга на деревьях решений. Главной особенностью используемого набора данных является подавляющее преобладание категориальных признаков. Традиционные подходы к машинному обучению требуют предобработки таких признаков, что на выборках объемом в десятки миллионов строк ведет к большому росту потребления оперативной памяти и вычислительных мощностей. CatBoost решает эту проблему, предлагая алгоритмически оптимизированные внутренние механизмы обработки категориальных данных без необходимости их предварительного явного кодирования.

Принцип градиентного бустинга заключается в последовательном построении ансамбля деревьев для минимизации функции потерь. Это позволяет эффективно улавливать нелинейные зависимости и сложные взаимодействия между характеристиками пользователя и параметрами аукциона. В совокупности это позволяет строить предиктивные модели стабильно высокого качества, отвечающие современным стандартам бизнес-аналитики.

Кроме того, CatBoost предоставляет широкий спектр инструментов для глубокой интерпретации обученной модели и понимания логики, согласно которой алгоритм принимает решения. С помощью метода `get_feature_importance()` из модели можно извлечь множество различных показателей важности признаков, которые помогают понять какие именно признаки и в какой степени влияют на прогнозирование целевой переменной. Библиотека позволяет оценивать глобальную важность каждого признака по отдельности, а также оценивать эффективность их попарного взаимодействия. Также в библиотеке реализован собственный функционал для вычисления SHAP-значений (SHapley Additive exPlanations). Эти значения позволяют детально для каждого отдельного объекта, количественно измерить влияние конкретного значения признака – то есть определить, насколько сильно оно уменьшает или увеличивает вероятность клика. Эти методы интерпретируемости модели позволяют сделать из модели «черного ящика» прозрачный инструмент с понятной мерой качества всех признаков и их взаимодействия.

В работе для оценки качества обученных моделей рассматриваются:

- *LogLoss* – функция потерь, которая уже является базой для задач классификации. Её минимизация позволяет оценить вероятность клика наиболее точно.
- *ROC-AUC* – метрика, определяющий способность алгоритма верно ранжировать объекты по классам.
- *Accuracy* – общая доля правильных предсказаний модели.

Для хранения и обработки десятков миллионов записей, характерных для рекламных логов, требуются специализированные база данных. В данной работе в качестве хранилища используется ClickHouse – колоночная аналитическая система управления базами данных. Поддержка ClickHouse интегрирована в Yandex DataLens, что является необходимым условием для выбора базы данных для дальнейшей работы. Она обеспечивает высокую скорость выполнения запросов на больших объемах структурированной информации, в частности набора данных Avazu.

Главным инструментом визуализации и конечной интерпретации данных в рамках данного исследования выступает Yandex DataLens – облачный сервис бизнес-аналитики (BI). Данная платформа позволяет напрямую подключаться к большому количеству баз данных и строить множество различных типов чартов: от базовых линейных графиков до сводных таблиц. Также Yandex DataLens предоставляет возможность собирать чарты в полноценные интерактивные дашборды, обеспечиваю-

щие удобный мониторинг ключевых метрик и показателей, наглядное представление результатов разведочного анализа.

2.1 Цель исследования

Цель работы заключается в проведении разведочного анализа данных (EDA) с использованием платформы Yandex DataLens для выявления зависимостей и скрытых закономерностей, влияющих на вероятность клика (CTR). Насколько эффективно инструменты разведочного анализа данных (EDA) на базе платформы Yandex DataLens позволяют выявить скрытые зависимости, определяющие вероятность клика (CTR) в интернет-рекламе?

2.2 Объект исследования

К объекту исследования автор относит аукционы реального времени (real-time bidding, RTB) между рекламодателями и Интернет-площадками, проводимые с целью демонстрации рекламы, на примере набора данных [15].

2.3 Предмет исследования

На примере указанного набора данных, автор рассматривает значимость вклада различных факторов аукциона в его результаты.

2.4 Методы исследования

- Программирование на языке Python с использованием библиотек pandas, numpy для обработки данных.
- Применение библиотеки CatBoost для построения модели машинного обучения.
- Форматирование и подготовка табличных данных средствами Excel и Python.
- Визуализация данных с использованием платформы Yandex DataLens.
- Разведочный анализ данных (EDA) для выявления закономерностей.
- Обзор академических источников и анализ существующих подходов к прогнозированию CTR.

2.5 Задачи исследования

Задачи проекта разделяются на две части: исследовательскую и программную, а именно:

- Исследовательская часть
 - Исследовать набор данных [15] и провести его описательный анализ.

- Провести обзор источников, использующих рассматриваемый набор данных.
- Сравнить качество работы CatBoost по определению вероятности клика на рекламное объявление с результатами участников соревнования Kaggle [15].
- Пройти курс «DataLens: анализ и визуализация данных» [16] для изучения возможностей платформы Yandex DataLens.
- Программная часть
 - Применить алгоритм CatBoost для предсказания вероятности клика по рекламному объявлению на примере набора данных [15].
 - Подключить набор данных и результаты соревнования Kaggle к платформе Yandex DataLens.
 - Разработать интерактивный дашборд для мониторинга ключевых метрик и анализа эффективности рекламных кампаний, а также наглядного представления результатов прогнозирования CatBoost'a.

2.6 Актуальность работы

В современном мире интернет-реклама является одним из ключевых инструментов продвижения товаров и услуг [17]. Эффективность рекламных кампаний напрямую зависит от точности прогнозирования кликабельности (CTR) объявлений [18]. Разработка методов анализа и визуализации данных для оценки факторов, влияющих на CTR, может позволить оптимизировать рекламные стратегии и повысить возврат инвестиций.

Использование современных платформ бизнес-аналитики, таких как Yandex DataLens, открывает новые возможности для интерактивного анализа больших объемов данных и создания наглядных дашбордов для принятия управленческих решений.

Таким образом можно считать, что **актуальность работы** продемонстрирована.

2.7 План работы

№	Этап работы	Срок выполнения
1	Изучение предметной области и постановка задачи	Декабрь 2025
2	Исследование набора данных и описательный анализ	Декабрь 2025
3	Обзор источников	Декабрь 2025

Таблица 2.1. План выполнения курсовой работы

4	Прохождение курса «DataLens: анализ и визуализация данных»	Январь 2026
5	Создание макета дашборда	Февраль - Март 2026
6	Применение алгоритма CatBoost для прогнозирования CTR	Март – Апрель 2026
7	Сравнение результатов с участниками конкурса Kaggle	Март – Апрель 2026
8	Подключение набора данных и результатов соревнования Kaggle	Апрель 2026
9	Создание основных чартов для дашборда	Апрель 2026
10	Сбор финальной версии дашборда	Апрель – Май 2026
11	Тестирование и оптимизация дашборда	Май 2026

Таблица 2.2. План выполнения курсовой работы

2.7.1 Графическое представление плана работы



КТ-1

4 февраля 2026

Рисунок 2.1. Диаграмма Ганта выполнения курсовой работы

3 Описание набора данных Click-Through Rate Prediction

3.1 Общая характеристика набора данных

Набор данных «Avazu Click-Through Rate Prediction» [15] представляет собой коллекцию данных о показах мобильной рекламы, собранных компанией Avazu в течение 10 дней. Данные содержат информацию о рекламных объявлениях, показанных пользователям мобильных устройств, и факте клика по ним.

Основные характеристики набора данных:

- Размер: 40 428 967 строк.
- Каждая запись содержит информацию о одном показе рекламного объявления и факте клика по нему.
- Период сбора: 10 дней (21 октября – 30 октября 2014 года).
- Целевая переменная: бинарная (клик/не клик).
- Количество признаков: 23.

3.2 Описание полей набора данных

Набор данных содержит поля, которые описаны в Таблицах 3.3 и 3.4:

Поле	Тип	Описание
id	string	Уникальный идентификатор записи
click	integer	Целевая переменная: 0 (нет клика), 1 (клик)
hour	integer	Временная метка в формате YU MMDDHH
C1	integer	Анонимизированная категориальная переменная
banner_pos	integer	Позиция баннера на странице
site_id	string	Идентификатор сайта
site_domain	string	Домен сайта
site_category	string	Категория сайта
app_id	string	Идентификатор приложения
app_domain	string	Домен приложения
app_category	string	Категория приложения
device_id	string	Идентификатор устройства
device_ip	string	IP-адрес устройства
device_model	string	Модель устройства

Таблица 3.3. Описание полей набора данных

Поле	Тип	Описание
device_type	integer	Тип устройства
device_conn_type	integer	Тип подключения устройства
C14	integer	Анонимизированная категориальная переменная
C15	integer	Анонимизированная категориальная переменная
C16	integer	Анонимизированная категориальная переменная
C17	integer	Анонимизированная категориальная переменная
C18	integer	Анонимизированная категориальная переменная
C19	integer	Анонимизированная категориальная переменная
C20	integer	Анонимизированная категориальная переменная
C21	integer	Анонимизированная категориальная переменная

Таблица 3.4. Описание полей набора данных (продолжение)

3.2.1 Распределение категорий сайтов

Анализ распределения категорий сайтов показывает высокую концентрацию показов в нескольких основных категориях. Всего в наборе данных представлено 26 уникальных категорий сайтов. Важно отметить, что категории сайтов представлены в виде хеш-кодов. Это сделано для анонимизации набора данных.





Рисунок 3.2. Распределение топ-3 категорий сайтов по количеству показов (в %)

Как видно из Рисунка 3.2, три наиболее популярные категории сайтов (50e219e0, f028772b, 28905ebd) составляют более 90% всех показов в наборе данных, что указывает на значительную неравномерность распределения и доминирование определенных типов веб-сайтов в рекламной сети.

3.2.2 Распределение категорий приложений

Анализ категорий приложений демонстрирует еще более выраженную концентрацию. В наборе данных представлено 36 уникальных категорий приложений. Значения – это хеш-коды для анонимизации.



Создано с помощью Datawrapper

Рисунок 3.3. Распределение топ-3 категорий приложений по количеству показов (в %)

Как показано на Рисунке 3.3, доминирующая категория приложений (07d7df22) составляет почти 65% всех показов, а две ведущие категории охватывают 88% трафик. Это говорит о преобладании определенных типов мобильных приложений в рекламной сети и указывает на специфику целевой аудитории платформы Avazu.

3.3 Временная динамика показов и кликов

Анализ временной динамики показов рекламы позволяет выявить закономерности в поведении пользователей в зависимости от времени.




Рисунок 3.4. Временной ряд показов и кликов рекламы, почасовая группировка

Как видно из Рисунка 3.4, временной ряд обладает выраженной периодичностью с заметными колебаниями активности в течение суток. Наблюдается стабильная динамика показов на протяжении всего периода наблюдения (21-30 октября 2014 года). Из этого можно сделать вывод, что рекламная платформа работала без перебоев. График кликов повторяет общую динамику графика показов, сохраняя пропорциональное соотношение. Значение CTR ведет себя относительно стабильно в течение всего периода наблюдения.

3.4 Пример данных

id	click	hour	C1	banner_pos	site_id	site_domain	site_category	app_id	app_domain	app_category	device_id	device_ip	device_model	device_type	device_conn_type	C14	...	C21
1 000 009 418 151 094 273	0	14 102 100	1005	0	1fbe01fe	f3845767	28905ebd	ecad2386	7801e8d9	07d7df22	a99f214a	ddd2926e	44956a24	1	2	15 706	...	79
10 000 169 349 117 863 715	0	14 102 100	1005	0	1fbe01fe	f3845767	28905ebd	ecad2386	7801e8d9	07d7df22	a99f214a	96809ac8	711ee120	1	0	15 704	...	79
10 000 371 904 215 119 486	0	14 102 100	1005	0	1fbe01fe	f3845767	28905ebd	ecad2386	7801e8d9	07d7df22	a99f214a	b3cf8def	8a4875bd	1	0	15 704	...	79
10 000 640 724 480 838 376	0	14 102 100	1005	0	1fbe01fe	f3845767	28905ebd	ecad2386	7801e8d9	07d7df22	a99f214a	e8275b8f	6332421a	1	0	15 706	...	79
10 000 679 056 417 042 096	0	14 102 100	1005	1	fe8cc448	9166c161	0569f928	ecad2386	7801e8d9	07d7df22	a99f214a	9644d0bf	779d90c2	1	0	18 993	...	157
10 000 720 757 801 103 869	0	14 102 100	1005	0	d6137915	bb1ef334	f028772b	ecad2386	7801e8d9	07d7df22	a99f214a	05241af0	8a4875bd	1	0	16 920	...	117
10 000 724 729 988 544 911	0	14 102 100	1005	0	8fda644b	25d4cfcd	f028772b	ecad2386	7801e8d9	07d7df22	a99f214a	b264c159	be6db1d7	1	0	20 362	...	157
10 000 918 755 742 328 737	0	14 102 100	1005	1	e151e245	7e091613	f028772b	ecad2386	7801e8d9	07d7df22	a99f214a	e6f67278	be74e6fe	1	0	20 632	...	23
10 000 949 271 186 029 916	1	14 102 100	1005	0	1fbe01fe	f3845767	28905ebd	ecad2386	7801e8d9	07d7df22	a99f214a	37e8da74	5db079b5	1	2	15 707	...	79
10 001 264 480 619 467 364	0	14 102 100	1002	0	84c7ba46	c4e18dd6	50e219e0	ecad2386	7801e8d9	07d7df22	c357dbff	f1ac7184	373ecbe6	0	0	21 689	...	23

Таблица 3.5. Примеры записей из набора данных (первые 10 строк)

3.5 Особенности набора данных

3.5.1 Анонимизация данных

Значительная часть полей в наборе данных анонимизирована для защиты конфиденциальности: IP-адреса устройств, идентификаторы сайтов и приложений хешированы. Некоторые категориальные переменные (C1, C14-C21) полностью анонимизированы.

3.5.2 Дисбаланс классов

Набор данных характеризуется ощутимым дисбалансом классов:

- Записи с кликами (click=1): 17%.
- Записи без кликов (click=0): 83%.

Не-кликов значительно больше, чем кликов. В реальной жизни часто так и происходит: большинство показов рекламы не приводят к кликам. Люди пропускают рекламные объявления.

3.6 Применение набора данных

- Прогнозирование вероятности клика по рекламному объявлению по характеристикам отображения рекламного баннера.
- Анализ факторов, влияющих на CTR (Click-Through Rate) рекламных объявлений.

4 Обзор академических источников

Рассматриваемый в работе набор данных [15] используется в различных исследованиях, например в работах [19–21].

В работе [19] авторы Li L. предложили модель предсказания CTR (Click-Through Rate) на основе глубоких нейронных сетей (DNN) в сочетании с механизмом эффективного канального внимания (ECANet). набор данных Avazu использовался в качестве одного из четырех основных набор данных для валидации предложенной модели DNN-ECA наряду с Criteo, KDD12 и MovieLens-1M. Авторы отмечают, что набор данных Avazu предоставляет богатую информацию через множество полей признаков, содержащих характеристики пользователей и атрибуты рекламы, и имеет классические сценарии применения в области предсказания CTR мобильной рекламы.

Исследование продемонстрировало, что набор данных Avazu хорошо подходит для оценки моделей предсказания CTR в условиях разреженных данных и множественных категориальных признаков, характерных для мобильной рекламы.

В работе [20] авторы Zhu J. и другие представили первый открытый бенчмарк для предсказания CTR, направленный на решение проблем воспроизводимости и несогласованности результатов в существующих исследованиях. набор данных Avazu был выбран в качестве одного из двух основных набор данных для комплексного бенчмаркинга наряду с Criteo. Авторы отмечают, что оба набора данных были выпущены ведущими рекламными компаниями, собраны из реальных логов кликов в производственной среде и содержат десятки миллионов образцов, что делает результаты бенчмаркинга значимыми для промышленных практик.

Исследование выявило критические факторы для настройки производительности на набор данных Avazu, включая предобработку данных (особенно порог фильтрации редких признаков), размер батча (рекомендуется 10000), размер эмбедингов, вес регуляризации. Работа подчеркивает необходимость стандартизированных протоколов оценки и открытых результатов бенчмаркинга для обеспечения воспроизводимости исследований в области предсказания CTR.

В работе [21] авторы Damaševičius R. и Zailskaitė-Jakštė L. предложили модель Human-Centric Cyber Security (HCCS), которая расширяет

концепцию 3U (user, usage, usability) методами искусственного интеллекта для предсказания CTR в контексте кибербезопасности и юзабилити веб-приложений. набор данных Avazu использовался для экспериментальной валидации (бенчмарка).

Авторы отмечают, что набор данных Avazu был сгенерирован из конкурса по предсказанию CTR компании Avazu 2015 года и состоит из 24 столбцов, большинство из которых являются категориальными переменными. Набор данных содержит 40 428 967 образцов (из которых 33 563 901 положительных и 6 886 566 отрицательных), 23 поля и 1 544 488 признаков. Из-за большого размера набора данных авторы использовали только 10% данных для обучения и тестирования. Данные были разделены на обучающую (70%), валидационную (10%) и тестовую (20%) выборки.

Исследование показывает важность набора данных Avazu для оценки моделей предсказания CTR в контексте кибербезопасности с применением методов искусственного интеллекта для противодействия кибератакам и обеспечения поддержки принятия решений.

Во всех рассмотренных исследованиях набор данных Avazu CTR Prediction [15] выполняет роль бенчмарка предложенных моделей машинного обучения. Набор данных предоставляет основу для сравнения различных подходов к предсказанию CTR, позволяя исследователям объективно оценить эффективность своих методов относительно существующих решений. Большой объем данных, реальное происхождение и высокая разреженность признаков делают набор данных репрезентативным для практических задач онлайн-рекламы и рекомендательных систем.

5 Проектирование и разработка макета интерактивного дашборда

5.1 Концепция и архитектура дашборда

Аналитические результаты, полученные в ходе разведочного анализа (EDA) и машинного обучения, требуют наглядного и интерактивного представления. Сухие цифры и статические графики часто оказываются недостаточными для оперативного принятия решений. Поэтому основой практической части данного исследования стала разработка единого интерактивного дашборда, объединяющего продуктовые метрики трафика, статистику набора данных и результаты предсказательной модели CatBoost.

В качестве основной платформы для реализации архитектурного решения была выбрана система для бизнес-аналитики Yandex DataLens. Платформа обладает широким инструментарием для создания связанных параметризованных визуализаций больших и нагруженных данных.

При проектировании архитектуры дашборда учитывались возможные потребности трех основных групп потенциальных пользователей. Это помогло определить то, какие данные надо размещать на дашборде, как их разделять и группировать. Три основные группы пользователей:

1. **Менеджеры проекта, руководители, рекламные площадки и рекламодатели:** нуждаются в высокоуровневом мониторинге ключевых показателей эффективности (показы, клики, CTR) и оценке рентабельности рекламных площадок.
2. **Дата-инженеры и дата-аналитики:** требуют инструментов для глубокого погружения в структуру данных, оценки качества выборки, выявления аномалий и изучения распределения признаков, в том числе анонимизированных.
3. **ML-инженеры:** используют дашборд для мониторинга качества работы предиктивной модели, анализа важности признаков, выделенной моделью, и сравнения полученных результатов с ожиданиями от модели.

Для удовлетворения потребностей всех групп пользователей была выбрана многостраничная (модульная) архитектура, построенная по принципу «от общего к частному». Для этого макет дашборда концептуально разделен на три независимые, но логически связанные вкладки.

5.2 Продуктовые показатели рекламы и бизнес-метрики

Первая вкладка разработанного дашборда выполняет функцию высокоуровневого аналитического отчета и фокусируется на продуктовой информации о рекламном трафике. Ее главная цель – предоставить инструментарий для оперативного мониторинга динамики кликабельности (CTR) и оценки общей эффективности рекламных размещений.

Визуальная архитектура вкладки выстроена по принципу детализации данных: от общих агрегированных показателей к глубоким срезам по платформам, площадкам и характеристикам пользователей.

В верхней части дашборда (Рисунок 5.5) располагается блок ключевых показателей эффективности (KPI). Здесь представлены сводные чарты общего количества показов и кликов, а также среднее значение CTR. Дополнительно в этот блок интегрирован миниатюрный линейный график, отражающий подневную динамику CTR, что позволяет с первого взгляда оценить наличие краткосрочных трендов или аномалий.



Рисунок 5.5. Шапка дашборда: блок ключевых показателей рекламного трафика

Под блоком показателей располагается раздел анализа временных рядов (Рисунок 5.6), предназначенный для выявления суточной цикличности в поведении пользователей.




Рисунок 5.6. Анализ временных рядов показов, кликов и CTR

Интерактивность данного раздела обеспечивается селекторами вида трафика (Site/App) и даты. Графики позволяют анализировать средний CTR, количество показов и кликов в детализации по часам и по дням недели. Других детализаций добавить не получится, так как в наборе данных содержится только информация за 10 дней. Нижний график визуализирует общий объем трафика за выбранный интервал, наглядно демонстрируя соотношение показов и совершенных кликов с течением времени. Селектор даты также влияет на все нижние блоки с чартами.

Дальнейшая детализация аналитики предполагает сравнение платформ (Рисунок 5.7). Раздел «Трафик и CTR: Site vs App» позволяет сопоставить объемы привлекаемого трафика и итоговую кликабельность между веб-сайтами и мобильными приложениями.




Рисунок 5.7. Сравнительный анализ трафика и CTR по платформам

В данном блоке предусмотрена визуализация уникальности аудитории: оценивается количество уникальных устройств (как совершивших клик, так и в целом увидевших рекламу), а также уникальных IP-адресов. Это позволяет бизнесу оценивать реальный охват рекламных кампаний по каждой платформе.

Для оценки рентабельности конкретных мест размещения был спроектирован срез по площадкам (Рисунок 5.8). С помощью селектора конкретных категорий пользователь может отфильтровать интересующий сегмент.




Рисунок 5.8. Анализ показателей в срезах площадок и позиций баннера

На гистограммах этого раздела отображается средний CTR в разрезе категорий сайтов и приложений. Отдельными чартами вынесен анализ показателей по позиционированию: графики показывают, как различные позиции баннера (Banner Pos) влияют на генерируемый объем трафика (показы и клики) и на итоговый показатель кликабельности.

Заключительный блок первой вкладки (Рисунок 5.9) посвящен поведенческому анализу в срезах характеристик пользователей и их устройств.




Рисунок 5.9. Анализ трафика в срезах пользовательских устройств

Сводные столбчатые диаграммы демонстрируют распределение объемов трафика и средний CTR в зависимости от типа устройства (Device Type) и типа подключения к сети (Connection Type). Для проведения максимально детализированного анализа в нижнюю часть макета интегрирована сводная таблица. В ней собирается статистика по конкретным моделям устройств (Device Model) для выявления технических сегментов аудитории, генерирующих наибольший процент трафика или демонстрирующие наивысшую конверсию в клик. Селекторы сортировки и отображаемое количество лучших также присутствуют на макете дашборда.

Отдельно хотелось отметить, что каждый логический блок с селекторами и чартами-селекторами влияет и на чарты соседних блоков этой вкладки.

5.3 Разведочный анализ данных (EDA) и структура набора данных

Вторая вкладка разработанного дашборда выполняет функцию аналитического инструмента для разведочного анализа данных (Exploratory Data Analysis). Ее основная задача – предоставить дата-аналитикам и исследователям наглядное представление о структуре набора данных Avazu, распределении ключевых признаков и наличии особенностей.

В макете вкладка была названа «Данные о данных». В её верхней части (Рисунок 5.10) расположены общие сведения.




Рисунок 5.10. Блок агрегированных метрик набора данных

Это блок содержит показатели количества уникальных IP-адресов, типов устройств, а также количество уникальных категорий сайтов и мобильных приложений. Он позволяет мгновенно оценить масштаб и вариативность рассматриваемой выборки.

Центральная часть вкладки (Рисунок 5.11) отведена под детальное сравнение объемов трафика в различных группировках.

Сравнение трафика в разных группировках




Рисунок 5.11. Анализ распределений и структуры трафика

Особое значение в этом блоке имеет круговая диаграмма «Клик / не клик», которая визуализирует целевую переменную. Данный график наглядно демонстрирует естественный дисбаланс классов, характерный для задач предсказания CTR. Ниже расположены интерактивные круговые диаграммы и гистограммы с селектором Top-N. Они позволяют понять распределение трафика по категориям сайтов, приложений, моделей устройств и типов подключений. Вывод топа сайтов и приложений с помощью столбчатых диаграмм дает возможность определить доминирующие площадки, которые концентрируют большую часть трафика.

Последние два блока вкладки (Рисунок 5.12) направлены на отображение на временной динамике количества уникальных значений и анализ анонимизированных признаков набора данных.




Рисунок 5.12. Динамика количества уникальных значений и анализ анонимных признаков

Линейный график верхнего блока на Рисунке 5.12 отображает количество уникальных устройств и IP-адресов в разрезе по дням. Это позволяет оценить стабильность потока аудитории в рекламную сеть в течение рассматриваемого периода по разным признакам. Последний блок содержит только столбчатую диаграмму «Количество уникальных значений по анонимным категориям». Поскольку набор данных Avazu включает ряд полностью анонимизированных признаков (C14–C21). Их наглядная визуализация позволяет оценить масштаб и внутреннее разнообразие скрытых признаков.

5.4 Оценка модели CatBoost и важность признаков

Третья вкладка разработанного дашборда представляет собой аналитический интерфейс для оценки качества классификации, интерпретации решений модели CatBoost и проведения внешнего бенчмаркинга. Данный раздел позволяет дата-сайентистам и ML-инженерам не только отслеживать агрегированные метрики точности, но и понимать логику, которой руководствуется алгоритм при прогнозировании CTR.

В верхней части макета (Рисунок 5.13) расположен блок глобальных метрик качества обученной модели.




Рисунок 5.13. Блок глобальных метрик качества модели

Здесь в виде показателей выводятся значения функции потерь (Log Loss) и площади под ROC-кривой (ROC AUC) – ключевых показателей для задачи бинарной классификации. Для оценки конкурентоспособности разработанного решения предусмотрен вывод сора (Score), полученного на отложенной выборке по результатам обучения, а также позиционирование этого результата относительно лидерборда соревнования Avazu на платформе Kaggle [22].

Центральный блок дашборда сфокусирован на интерпретируемости модели и визуализации влияния признаков на целевую переменную. На Рисунке 5.14 представлена визуализация метрики Lift.



Рисунок 5.14. Анализ прироста вероятности клика (Lift)

График Lift демонстрирует, насколько конкретные значения в выбранных категориях (например, определенная модель устройства или позиция баннера) дают статистический прирост или, напротив, уменьшают сред-

нее значение CTR. Для более глубокого анализа предусмотрена детализированная таблица, отображающая название колонки, ее конкретное значение, процентную прибавку к CTR и долю такого трафика в общей выборке.

Дальнейшая интерпретация решений алгоритма реализуется через анализ важности признаков, представленный на Рисунке 5.15.



Рисунок 5.15. Анализ важности признаков и их взаимодействия

Верхняя таблица визуализирует метрику Feature Importance, встроенную в алгоритм CatBoost. Она ранжирует признаки по степени их суммарного вклада в предсказательную способность модели. Нижняя таблица развивает эту идею, демонстрируя лучшие связки признаков (Feature Interactions). Данный график позволяет находить ситуации, когда комбинация двух независимых переменных (Колонка 1 и Колонка 2) оказывает на вероятность клика более сильное влияние, чем каждый из этих признаков по отдельности. Оценка силы взаимодействия признаков выражается количественно в виде показателя Score.

Заключительный блок третьей вкладки (Рисунок 5.16) посвящен анализу калибровки вероятностей и оценке смещения предсказаний.




Рисунок 5.16. Анализ калибровки модели и сравнение CTR

Верхние столбчатые диаграммы в данном блоке сравнивают реальный средний CTR с усредненным значением вероятностей, предсказанных моделью, в срезах различных категорий. Это позволяет выявить системные ошибки алгоритма на определенных частях трафика. Но главным графиком этого блока является «Диаграмма надежности модели» (Reliability Diagram). Она отображает соотношение предсказанной вероятности и фактической доли положительных классов. Отклонение синей кривой (фактических предсказаний CatBoost) от пунктирной диагонали (идеально откалиброванной модели) позволяет диагностировать зоны недопредсказанного или перепредсказанного CTR.

Все чарты и показатели были получены на отложенной валидационной выборке и отражают реальную точность модели.

6 Обучение модели CatBoost для предсказания CTR

Модель CatBoost необходима для получения результатов в Kaggle соревновании, а также для построения чартов с третьей вкладки макета дашборда.

6.1 Подготовка данных для обучения модели

Перед обучением модели CatBoost была проведена предварительная обработка данных. Основной задачей являлось формирование обучающей и валидационной выборок, а также корректная работа с категориальными признаками.

В набор данных от Avazu все признаки модели, за исключением времени, являются категориальными. Одним из ключевых преимуществ CatBoost является встроенная поддержка категориальных признаков без необходимости их явного кодирования: библиотека сама решает, что делать с ними.

Сам набор данных очень объемный (40 млн. строк) и хранить его целиком в памяти во время обучения не представляется возможным. Также обучение на таком объеме данных требует большого количества вычислительных ресурсов. Было принято решение предобработать данные локально до обучения и сохранить их для дальнейшего использования.

Все данные были разбиты на 2 выборке: обучающую и валидационную. Так как наши данные времязависимые, то была использован Out-of-Time (OOT) подход: более ранние данные использовались для обучения, а более поздние для валидации. Одним из условий, которым соответствует набор данных, является то, что они изначально были отсортированы по времени. Это дало возможность читать их последовательно из файла по частям, предобрабатывать и сохранять в нужную выборку. Первые 30 000 000 строк были использованы в качестве обучающей выборки, остальные 10 428 967 в качестве валидационной. Это примерно разбиение в соотношении 74:26.

Предобработанные данные получались следующим образом: тренировочные данные читались последовательно частями по 5 млн. строк, для текущей части определялась выборка: обучающая или валидационная, далее к данным применялась функция `data_transformer` из Листинга 6.1 и далее сохранялась в соответствующую выборку на диск.

```
def data_transformer(df: pd.DataFrame):
    dt = pd.to_datetime(df['hour'], format='%y%m%d%H')
    df['day_of_week'] = dt.dt.dayofweek
    df['hour_of_day'] = dt.dt.hour

    return df.drop(columns=['id', 'hour'], axis=1).astype(str)
```

Листинг 6.1. Функция `data_transformer` для предобработки данных

Функция из Листинга 6.1 применена для упрощения колонки `hour`, которая содержит временную метку (Timestamp). Она преобразовывается в столбцы `day_of_week` и `hour_of_day` – день недели и час: понятные и простые для обучения категориальные признаки.

6.2 Выбор платформы для обучения модели

Обучение модели на центральном процессоре (CPU) заняло бы несколько дней, в связи с чем было принято решение задействовать графический ускоритель (GPU). Рассматривались три варианта: использование локальной видеокарты, среда Google Colab с бесплатным доступом к ускорителю NVIDIA T4 и платформа Kaggle, предоставляющая GPU NVIDIA P100. Окончательный выбор был сделан в пользу Kaggle, поскольку эта среда отличается прозрачными условиями использования бесплатного GPU и позволяет выполнять вычисления в фоновом режиме, что очень удобно для долгого процесса обучения модели.

Так как Kaggle платформа, на которой хранятся большое количество наборов данных и соревнований по машинному обучению, то на ней можно создать собственный набор данных. Локально предобработанные данные были загружены на платформу и далее использовались для обучения модели.

6.3 Обучение модели CatBoost

Обучающая и валидационная выборки передавались в модель через Pool'ы, которые представлены в библиотеке CatBoost. Pool – это специализированная структура данных, предназначенная для эффективного хранения и передачи обучающего набора в алгоритмы градиентного бустинга. Она инкапсулирует не только матрицу признаков и вектор целевой переменной, но и метаданные о категориальных столбцах. Использование Pool позволяет CatBoost оптимизировать вычисления на GPU, избегая избыточного копирования данных и автоматически применяя встроенные методы обработки категорий. В рамках данного обучения в Pool были переданы все исходные признаки, а также 2 созданных

вручную признака: `day_of_week` и `hour_of_day`. Все они были размечены как категориальные.

```
model = CatBoostClassifier(
    iterations=3000,
    learning_rate=0.03,
    depth=7,
    l2_leaf_reg=3,
    eval_metric='AUC',
    loss_function='Logloss',
    od_type='Iter',
    od_wait=200,
    use_best_model=True,
    max_ctr_complexity=2,
    ctr_leaf_count_limit=32,
    random_strength=0.5,
    has_time=True,
    bagging_temperature=1,
    border_count=64,
    random_seed=67,
    task_type='GPU',
    gpu_ram_part=0.7,
    verbose=100
)
```

Листинг 6.2. Инициализация модели CatBoost с параметрами обучения

Все передаваемые параметры модели представлены в Листинге 6.2. Большинство из них подбирались империческим путем или путем нескольких запусков. Выпишем ключевые параметры, которые больше всего влияют на качество обучения модели:

- `iterations=3000` – количество итераций обучения. Специально взято с запасом, так как есть критерий останова.
- `learning_rate=0.03` – скорость обучения (шаг градиентного спуска). Подбери́лось империческим путем по количеству итераций.
- `depth=7` – максимальная глубина деревьев решений. На первых порах подбора параметров было установлено значение 8, но оно оказалось излишним.
- `l2_leaf_reg=3` – коэффициент L2-регуляризации весов листьев. Штрафует большие значения прогнозов в листьях, предотвращая переобучение. Значение 3 является умеренным и подходит для объёмных данных с высоким уровнем шума.
- `eval_metric='AUC'` – метрика, вычисляемая на валидационном наборе в процессе обучения для оценки качества и ранней остановки.
- `loss_function='Logloss'` – функция потерь для задачи классификации.

- `od_type='Iter'` и `od_wait=200` – параметры для ранней остановки обучения. В данном случае, если на протяжении 200 деревьев метрика на валидации не улучшается, обучение прекращается.
- `max_ctr_complexity=2` – учитываются комбинации не более чем из двух категориальных признаков. При больших значениях обучение занимало больше времени.
- `ctr_leaf_count_limit=32` – ограничение на количество объектов при вычислении CTR для снижения переобучения.
- `has_time=True` – указание модели, что данные содержат временную информацию.
- `task_type='GPU'` – использование GPU для обучения.
- `gpu_ram_part=0.7` – доля доступной памяти GPU, которую CatBoost может использовать для размещения данных и промежуточных структур. Без этого параметра обучение завершалось с ошибкой из-за нехватки памяти.

После обучения модель сохранялась для дальнейшего использования локально, а не в Kaggle. Итоговый вес модели составил 8.57 гигабайт.

6.4 Итоговые показатели модели на валидационной и тестовой выборках

По итогам обучения модели на валидационной выборке удалось получить следующие результаты:

- $\text{ROC-AUC} = 0.7548$
- $\text{LogLoss} = 0.3831$
- $\text{Accuracy} = 0.8449$

После применения модели к тестовой выборке был сохранен файл `submission.csv` а далее загружен на Kaggle в качестве решения. По итогу был получен такой результат [6.17](#).

Submission and Description		Private Score ⓘ	Public Score ⓘ
 submission.csv Complete (after deadline) · 5d ago · CatBoost model with more iterations and params, learning by Kaggle GPU			
		0.39882	0.40051

Рисунок 6.17. Результаты послыки решения на Kaggle


Если посмотреть по таблице лидеров, то текущий результат дает 1045 место. Стоит отметить, что в соревновании Avazu Click-Through Rate Prediction результаты сравниваются по LogLoss (тем меньше, чем лучше). Лучший результат соревнования – $\text{LogLoss} = 0.37913$.

7 Подготовка и загрузка данных для дашборда

Чтобы полноценно реализовать построенный макет интерактивного дашборда в Yandex DataLens, надо подключить все необходимые для чартов источники данных. Чарты с первых двух вкладок макета дашборда требуют только полный набор данных: всю агрегацию и предобработку данных можно выполнить на самой платформе Yandex DataLens. Третья вкладка требует метрик и сводных данных от обученной модели CatBoost.

Так как напрямую набор данных загрузить в Yandex DataLens нельзя из-за его большого объема, пришлось искать подходящую базу данных из тех, подключения к которым поддерживает платформа DataLens.

Базы данных



Файлы и сервисы




Рисунок 7.18. Источники данных в Yandex DataLens

В итоге в качестве СУБД был выбран ClickHouse, поскольку Яндекс сам рекомендует его для работы с Yandex DataLens. Кроме того, важным фактором стал доступный бесплатный период использования, что позволило развернуть хранилище и протестировать интеграцию без дополнительных затрат. Колончатая структура ClickHouse также обеспечивает высокую скорость выполнения аналитических запросов, что особенно важно при работе с большими объемами данных и построении интерактивных дашбордов.

7.1 Подготовка ClickHouse и загрузка данных

После регистрации на платформе ClickHouse была создан сервис с самой дешевой конфигурацией.




Рисунок 7.19. Сервис «Avazu CTR Prediction Dataset» в ClickHouse




Рисунок 7.20. Конфигурация сервиса «Avazu CTR Prediction Dataset»

Целиком загрузить за раз весь набор данных не получилось даже в ClickHouse, поэтому он отправлялся по частям с помощью Python-библиотеки `clickhouse_connect`. Она предоставляет удобный интерфейс для подключения к базе данных, выполнения SQL-запросов и пакетной вставки данных, что особенно полезно при работе с большими объемами (как у нас). Благодаря этому данные разбивались на небольшие чанки и последовательно загружались в таблицы, что позволило избежать переполнения памяти и сетевых ограничений.

```

CREATE TABLE avazu_ctr_prediction_data
(
    id String,
    click UInt8,
    hour UInt64,
    C1 Int32,
    banner_pos Int32,
    site_id String,
    site_domain String,
    site_category String,
    app_id String,
    app_domain String,
    app_category String,
    device_id String,
    device_ip String,
    device_model String,
    device_type Int32,
    device_conn_type Int32,
    C14 Int32,
    C15 Int32,
    C16 Int32,
    C17 Int32,
    C18 Int32,
    C19 Int32,
    C20 Int32,
    C21 Int32
)
ENGINE = MergeTree
ORDER BY (hour, id);

```

Листинг 7.3. SQL запрос для создания таблицы в ClickHouse

Для начала была создана таблица в ClickHouse с помощью запроса из Листинга 7.3. Таблица была названа `avazu_ctr_prediction_data`. Далее в нее производилась вставка данных по 1 млн. строк за один запрос.

После этих действий в ClickHouse появилась таблица, содержащая весь набор данных.

7.2 Извлечение необходимых метрик и сводных данных из модели CatBoost

Как было сказано ранее, для третьей вкладки дашборда необходимо получить метрики и сводные таблицы от обученной модели CatBoost. Мы уже обучили модель, как описано в главе «Обучение модели CatBoost». Далее будем использовать ее. Все возможные данные собирались на валидационной выборке.

7.2.1 Базовые метрики на валидационной выборке

Базовые метрики качества были получены с помощью библиотеки `sklearn`, в частности модуля `metrics`, как это представлено в Листинге 7.4. После чего метрики были сохранены в файл `model_metrics.csv`.

```
from sklearn.metrics import roc_auc_score, log_loss

roc_auc = roc_auc_score(val_df[target], val_df[predicted_ctr])
logloss = log_loss(val_df[target], val_df[predicted_ctr])
```

Листинг 7.4. Подсчет метрик качества на валидационной выборке

7.2.2 Данные для чартов из Lift блока

CatBoost представляет широкий функционал для определения того, почему модель сделала тот или иной выбор. Основным инструментом для этого является метод `get_feature_importance()`, который есть у класса модели `CatBoostClassifier`. У него есть параметр `type`, который позволяет получить различную информацию о важности признаков, полученную в ходе обучения модели.

Для сбора Lift показателей по категориям был использован метод с параметром `type='ShapValues'`. В этом режиме метод возвращает значения SHAP (SHapley Additive exPlanations) для каждого объекта и каждого признака – то есть вклад каждого признака в итоговое предсказание модели. Результат представляет собой матрицу, где для каждой строки (объекта) указаны значения влияния всех признаков, а также дополнительный столбец с базовым значением (средним предсказанием модели).

Положительные значения SHAP показывают, что признак увеличивает вероятность целевого класса, отрицательные – уменьшают. Это позволяет не только оценить глобальную важность признаков, но агрегировать вклады по категориям для расчета Lift метрик.

```

all_shap_values = model.get_feature_importance(val_pool, type='ShapValues')

shap_values_only = all_shap_values[:, :-1]
shap_df = pd.DataFrame(shap_values_only, columns=categorical_features)[categorical_features]

total_traffic = len(val_df)
shap_lift_data = []

for category_name in categorical_features:
    temp_df = pd.DataFrame({
        'category_value': val_df[category_name].values,
        'shap_value': shap_df[category_name].values
    })

    grouped = temp_df.groupby('category_value').agg(
        traffic=('shap_value', 'count'),
        avg_shap=('shap_value', 'mean')
    ).reset_index()

    grouped['category_name'] = category_name
    grouped['traffic_share'] = (grouped['traffic'] / total_traffic)

    shap_lift_data.append(grouped[['category_name', 'category_value', 'avg_shap', 'traffic_share']])

shap_lift_df = pd.concat(shap_lift_data, ignore_index=True)

```

Листинг 7.5. Подсчет Lift метрики для категорий

Листинг 7.5 содержит код для подсчета Lift метрики для категорий. Стоит отметить, что одновременно с подсчетом пользы конкретного значения категории также собиралась доля трафика, которая относится к этой категории.

Итоговые агрегации были сохранены в файл `shap_lift.csv`.

7.2.3 Полезность признаков

Это базовая метрика CatBoost модели, которая отражает вклад каждого признака в целевую переменную. Это базовый тип метрики, который возвращает метод `get_feature_importance()`. Таблица Feature Importance была сохранена в файл `feature_importance.csv`.

```

feature_importance = model.get_feature_importance()
importance_df = pd.DataFrame({
    'feature': model.feature_names_,
    'importance': feature_importance
})

```

Листинг 7.6. Подсчет Feature Importance CatBoost модели

7.2.4 Качество влияния на целевую связок признаков

Для получения этой метрики был использован метод `get_feature_importance()` вызывается с параметром `type='Interaction'`. В этом режиме метод возвращает список попарных взаимодействий признаков в табличном виде, где в третьей колонке содержится качество влияния пары на целевую переменную. Результат преобразования этого списка был сохранен в файл `feature_interactions.csv`.

```
interaction_importance = model.get_feature_importance(type="Interaction")

interactions_df = pd.DataFrame(
    interaction_importance,
    columns=['feature_1_idx', 'feature_2_idx', 'interaction_score']
)

feature_names = model.feature_names_
interactions_df['feature_1'] = interactions_df['feature_1_idx'].apply(lambda x: feature_names[int(x)])
interactions_df['feature_2'] = interactions_df['feature_2_idx'].apply(lambda x: feature_names[int(x)])
interactions_df = interactions_df[['feature_1', 'feature_2', 'interaction_score']]
```

Листинг 7.7. Подсчет Feature Importance CatBoost модели

7.2.5 Предсказанный CTR в сравнении с реальным в срезах разных признаков В этом блоке был рассчитан средний реальный CTR и средний предсказанный CTR в группировке по следующим признакам: `site_category`, `app_category`, `device_model`, `device_type`. Результат сохранен в файл `diff_ctr.csv`.

```
needable_categorical_features = ['site_category', 'app_category', 'device_model', 'device_type']

for category_name in needable_categorical_features:
    grouped = val_df.groupby(category_name).agg({'target': 'mean', 'predicted_ctr': 'mean'}).reset_index()
    grouped.columns = ['category_value', 'real_ctr', 'predicted_ctr']
    grouped['category_name'] = category_name

    diff_ctr_data.append(grouped)

diff_ctr_df = pd.concat(diff_ctr_data, ignore_index=True)
```

Листинг 7.8. Вычисления среднего реального и предсказанного CTR в группировке по разным признакам

7.2.6 Данные для диаграммы надежности модели

В этом блоке была рассчитана калибровка модели – соответствие предсказанных вероятностей реальным значениям целевой переменной. Для этого использовалась функция `calibration_curve` из библиотеки `sklearn.calibration`, которая разбивает предсказания на интервалы (бины) и для каждого из них вычисляет средний предсказанный CTR и фактическую долю положительных исходов. Результат сохранен в файл `calibration_curve.csv`

```
from sklearn.calibration import calibration_curve

prob_true, prob_pred = calibration_curve(val_df[target], val_df[predicted_ctr], n_bins=10, strategy='uniform')

calibration_df = pd.DataFrame({
    'predicted_ctr': prob_pred,
    'real_ctr': prob_true
})
calibration_df['perfect_calibration'] = calibration_df['real_ctr']
```

Листинг 7.9. Вычисления среднего реального и предсказанного CTR в группировке по разным признакам

7.3 Подключение источников данных в Yandex DataLens

7.3.1 Подключение ClickHouse

Для подключения ClickHouse к Yandex DataLens потребовалось указать путь базы данных и порт интерфейса, как это показано на Рисунке 7.21.

← ClickHouse

Подключение: Выбрать в организации Указать вручную Connection Manager

Указать реквизиты БД вручную. Для подключения через публичную сеть.

Имя хоста:

Порт HTTP-интерфейса: ×

Имя пользователя:

Пароль:

Время жизни кеша: По умолчанию Настраиваемое

Рисунок 7.21. Источники данных в Yandex DataLens

После чего у меня появилось подключение к базе данных в ClickHouse и доступ к таблице `avazu_ctr_prediction_data`.

7.3.2 Подключение метрик и сводных таблиц из модели CatBoost

Yandex DataLens позволяет удобным образом загружать CSV файлы прямо на платформу (можно увидеть на Рисунке 7.18). Поэтому все необходимые CSV файлы были просто загружены в Yandex DataLens.

По итогам были получены 2 источника данных. Они представлены на Рисунке 7.22.

▼ Подключения

	ClickHouse Avazu Click-Through Rate Prediction	wip-62	4 дня назад
	Model evaluation on validation data	wip-62	4 дня назад

Рисунок 7.22. Все созданные подключения в Yandex DataLens

7.4 Создание датасетов в Yandex DataLens

Из подключений были созданы все необходимые для чартов датасеты. Они представлены на Рисунке 7.23.

▼ Датасеты

	Lift результаты модели	wip-62	4 дня назад
	Данные для диаграммы надежности	wip-62	4 дня назад
	Датасет Avazu Click-Through Rate Prediction	wip-62	несколько секунд назад
	Качество связей признаков	wip-62	4 дня назад
	Метрики модели	wip-62	4 дня назад
	Полезность признаков	wip-62	4 дня назад
	Средний предсказанный и реальный CTR	wip-62	4 дня назад

Рисунок 7.23. Все созданные датасеты в Yandex DataLens

В каждом датасете были проведены преобразования колонок типов данных, а также все названия колонок были переведены на русский с понятным значением для удобства дальнейшего использования.

8 Заключение

Выполнение данной исследовательской работы позволило на практике продемонстрировать высокую эффективность совместного применения методов машинного обучения и современных BI-платформ для анализа масштабных рекламных логов.

Заключение суммаризирует ключевые результаты проведенного исследования, содержит детальное описание разработанной версии дашборда, содержит объективные ограничения текущей версии и определяет возможные направления её дальнейшего масштабирования.

8.1 Описание выполненных задач

В ходе выполнения данной курсовой работы были в полном объеме реализованы все исследовательские и программные задачи, поставленные на начальном этапе проектирования:

- Исследование набор данных [15] и его описательный анализ. Результаты исследования представлены в Главе 3. Артефактами являются таблицы описания полей (Таблицы 3.3 и 3.4), построенные визуализации распределения категорий сайтов и приложений (Рисунки 3.2 и 3.3), также визуализация почасовой динамики трафика (Рисунок 3.4).
- Обзор источников, использующих рассматриваемый набор данных. В Главе 4 представлен разбор трех современных профильных исследований, использовавших набор данных от Avazu как бенчмарк для валидации алгоритмов предсказания CTR.
- Прохождение курса «DataLens: анализ и визуализация данных» [16] для изучения возможностей платформы Yandex DataLens. Диплом, подтверждающий прохождение курса, приложен к отчету. TODO!
- Применение алгоритма CatBoost для предсказания вероятности клика по рекламному объявлению на примере набора данных [15]. Код обучения и применения модели доступен [в репозитории](#). Процесс предобработки данных, обучения и валидации модели подробно описан в Главе 6.
- Сравнение качества работы CatBoost по определению вероятности клика на рекламное объявление с результатами участников соревнования Kaggle [15]. Результаты представлены в Главе 6.4, ключевым является Рисунок 6.17 с результатами посылки предсказаний.

- Подключение набор данных и результаты соревнования Kaggle к платформе Yandex DataLens. Описание процесса выполнения задачи представлено в Главе 7.3. Итогом стали добавленные в Yandex DataLens датасеты. Они представлены на Рисунке 7.23.
- Разработка интерактивного дашборда для мониторинга ключевых метрик и анализа эффективности рекламных кампаний, а также наглядного представления результатов прогнозирования CatBoost'a. Описание макета дашборда представлено в Главе 5. Результатом является полностью функционирующий готовый дашборд, который доступен [по ссылке](#). Он отличается от макета. Его детализированное описание представлено в Главе 8.3.

8.2 Описание структуры Git репозитория

Ниже представлена структура исходного кода и материалов курсовой работы. Репозиторий разбит на 2 логические части – исходный код и файлы верстки отчета.

- `code/` – директория с Python-скриптами и Jupyter Notebook, используемыми для предобработки данных, загрузки набора данных в ClickHouse, проведения исследовательского анализа данных (EDA), обучения моделей машинного обучения и генерации предсказаний.
 - `code/catboost/` – ноутбуки, связанные с обучением модели CatBoost, валидацией качества и формированием итогового submission-файла для соревнования на платформе Kaggle.
 - `code/data_extraction_for_report/` – скрипты для построения графиков, таблиц и агрегированных метрик, используемых в аналитической части курсовой работы и визуализациях отчета.
- `typst/` – исходные файлы отчета курсовой работы, подготовленные с использованием языка верстки Typst. Директория включает главы отчета, библиографию, изображения и вспомогательные шаблоны оформления.

8.3 Описание интерактивной визуализации

Разработка единого интерактивного дашборда стала основой практической частью исследования. При проектировании архитектуры учитывались потребности трех основных групп пользователей:

- Менеджеры проекта, руководители, рекламные площадки и рекламодатели
- Дата-инженеры и дата-аналитики

- ML-инженеры

При разработки концепции ждя удовлетворения этих запросов была выбрана многостраничная архитектура, концептуально разделенная на три независимые, но логически связанные вкладки. Но при построении итогового дашборда было принято решение разбить каждую вкладку на несколько по блокам.

TODO!

8.4 Ответ на основной вопрос работы

Основной вопрос исследования формулировался следующим образом: насколько эффективно инструменты разведочного анализа данных (EDA) на базе платформы Yandex DataLens позволяют выявить скрытые зависимости, определяющие вероятность клика (CTR) в интернет-рекламе?

На основе полученных результатов исследования можно сделать вывод, что выбранный подход отлично подходит для ответа на этот вопрос. С помощью разработанных интерактивных визуализаций удалось наглядно показать ключевые закономерности распределения трафика (доминирование конкретных категорий сайтов и приложений) и зафиксировать устойчивую суточную периодичность кликов и показов. Через чатры Yandex DataLens получилось превратить обученный алгоритм CatBoost из «черного ящика» в прозрачный инструмент и определить признаки, ключевые для CTR, и их значения с помощью lift-графика и таблицы, таблицы feature importance и других показателей, представленных на дашборде.

Таким образом, разработанные визуальные и предиктивные решения являются достаточными для качественной оценки факторов аукциона реального времени (RTB).

8.5 Ограничения работы

В процессе исследования автор столкнулся с рядом существенных объективных сложностей и ограничений, накладывающих рамки на полученные результаты.

Размер набора данных, что физически невозможно обрабатывать целиком в оперативной памяти стандартных вычислительных машин. Это потребовало разработки алгоритмов локального батчевания данных

почти при всех взаимодействиях с данными. Особенно обучение модели на таком объеме данных требует специальных конструкций.

Также размер данных очень сильно влияет на время агрегации для отображения актуальных чартов на дашборде. Расчет всех чартов на основе всех 40 миллионов строк занимал больше 1 минуты, что очень долго. Эту проблему пришлось решать с помощью семплирования, то есть взятия случайных строк для уменьшения количества данных, используемых для построения чартов.

Второй проблемой, с которой пришлось столкнуться при выполнении данной работы, стала полная анонимизация всех категориальных признаков. Поскольку идентификаторы устройств, сайтов, приложений и IP-адреса представлены в виде хешированных значений, а содержательный смысл колонок C14–C21 полностью скрыт, провести глубокий продуктовый анализ с опорой на знания о реальном мире полученных зависимостей не представляется возможным.

8.6 Развитие работы

В качестве векторов дальнейшего развития и улучшения текущего исследовательского проекта автор выделить следующие направления для изменений:

- Автоматизация подбора гиперпараметров: замена эмпирического подбора ключевых конфигураций модели на систематический автоматизированный поиск.
- Эксперименты различными с моделями для предсказания CTR: градиентный бустинг – стандарт классического машинного обучения, но он не всегда выдает лучшие результаты. Возможно, можно подобрать оптимальную архитектуру для нейронной сети, чтобы улучшить качество и интерпретируемость предиктивной модели.
- В качестве самого перспективного направления развития автор выделяет переход к потоковой аналитике. Модернизация архитектуры хранения данных ClickHouse для обработки не исторических статических данных, а непрерывных real-time потоков логов, поступающих напрямую с рекламных аукционов (RTB) в режиме реального времени.

9 Описание применения генеративной модели

В рамках выполнения работы использовались технологии генеративного искусственного интеллекта для двух задач, которые описаны ниже.

9.1 Верстка отчета для курсовой работы на языке Typst

Целью применения модели было изучение возможностей и синтаксиса верстки документов на языке Typst, а также адаптация и перенос существующего шаблона из формата LaTeX в формат Typst.

Для этой задачи использовалась модель Claude Sonnet 3.5 от компании Anthropic. Доступ к модели осуществлялся через специализированное внутреннее корпоративное расширение компании Яндекс для среды разработки Visual Studio Code. Прямой адрес сети «Интернет» не использовался.

Модель применялась в агентском режиме путем ввод текстовых запросов в чат-интерфейсе расширения. Ответы содержали разбор возможностей языка Typst или сгенерированный код на языке Typst. Модель применялась для написания фрагментов кода, поиска оптимальных решений для верстки и трансляции конструкций LaTeX в конструкции Typst.

9.2 Изучение возможностей библиотеки CatBoost

Целью применения модели являлось изучение технических особенностей и синтаксиса библиотеки машинного обучения CatBoost, а также практическое применение инструментов для работы с данными и настройки процесса обучения моделей.

Для реализации данной задачи использовалась модель Gemini 3.1 Pro от Google. Доступ к модели осуществлялся через официальный сайт. Адрес сети «Интернет»: <https://gemini.google.com>.

Модель применялась как чат-бот в диалогом окне на сайте. Ответы были в текстовом формате с наличием примеров использования библиотеки CatBoost в рамках конкретного вопроса в виде кода на языке Python. Модель использовалась для изучения доступных параметров моделей, возможностей обучения на огромном объеме данных без возможности хранения в памяти, а также для изучения метрик, доступных для извлечения из модели.

Список литературы

1. Википедия. CTR (Интернет) [Электронный ресурс]. 2025. URL: [https://ru.wikipedia.org/wiki/CTR_\(%D0%98%D0%BD%D1%82%D0%B5%D1%80%D0%BD%D0%B5%D1%82\)](https://ru.wikipedia.org/wiki/CTR_(%D0%98%D0%BD%D1%82%D0%B5%D1%80%D0%BD%D0%B5%D1%82)) (дата обращения: 12.12.2025).
2. Yandex Cloud. Основные понятия DataLens [Электронный ресурс]. 2025. URL: <https://yandex.cloud/ru/docs/datalens/concepts/> (дата обращения: 12.12.2025).
3. Википедия. Разведочный анализ данных [Электронный ресурс]. 2025. URL: https://ru.wikipedia.org/wiki/%D0%A0%D0%B0%D0%B7%D0%B2%D0%B5%D0%B4%D0%BE%D1%87%D0%BD%D1%8B%D0%B9_%D0%B0%D0%BD%D0%B0%D0%BB%D0%B8%D0%B7_%D0%B4%D0%B0%D0%BD%D0%BD%D1%8B%D1%85 (дата обращения: 12.12.2025).
4. Википедия. Kaggle [Электронный ресурс]. 2025. URL: <https://ru.wikipedia.org/wiki/Kaggle> (дата обращения: 14.12.2025).
5. Yandex. Cat Boost [Электронный ресурс]. 2026. URL: <https://catboost.ai/> (дата обращения: 01.04.2026).
6. Википедия. Диаграмма [Электронный ресурс]. 2026. URL: <https://ru.wikipedia.org/wiki/%D0%94%D0%B8%D0%B0%D0%B3%D1%80%D0%B0%D0%BC%D0%BC%D0%B0> (дата обращения: 20.03.2026).
7. РБК Life. Что такое дашборд и как сделать его самостоятельно. Примеры инструментов для создания [Электронный ресурс]. 2025. URL: <https://www.rbc.ru/life/news/6722aee79a79476dcf47ea95> (дата обращения: 14.12.2025).
8. Yandex Cloud. Чарт в Yandex DataLens [Электронный ресурс]. 2026. URL: <https://yandex.cloud/ru/docs/datalens/concepts/chart> (дата обращения: 20.03.2026).
9. Yandex Cloud. Виджеты в Yandex DataLens [Электронный ресурс]. 2026. URL: <https://yandex.cloud/ru/docs/datalens/dashboard/widget> (дата обращения: 20.03.2026).
10. Yandex Cloud. Селекторы в Yandex DataLens [Электронный ресурс]. 2026. URL: <https://yandex.cloud/ru/docs/datalens/dashboard/selector> (дата обращения: 20.03.2026).

11. Яндекс Образования – Учебник по машинному обучению. Линейные модели [Электронный ресурс]. 2026. URL: <https://education.yandex.ru/handbook/ml/article/linear-models#linejnaya-klassifikaciya> (дата обращения: 01.04.2026).
12. Яндекс Образования – Учебник по машинному обучению. Метрики классификации и регрессии [Электронный ресурс]. 2026. URL: <https://education.yandex.ru/handbook/ml/article/metriki-klassifikacii-i-regressii> (дата обращения: 01.04.2026).
13. Википедия. ClickHouse [Электронный ресурс]. 2026. URL: <https://ru.wikipedia.org/wiki/ClickHouse> (дата обращения: 09.04.2026).
14. Skillbox. Что такое Jupyter Notebook [Электронный ресурс]. 2026. URL: <https://skillbox.ru/media/code/jupyter-notebook-cto-eto-za-programma-i-dlya-chego-ona-nuzhna/> (дата обращения: 18.05.2026).
15. Kaggle. Avazu Click-Through Rate Prediction [Электронный ресурс]. 2025. URL: <https://www.kaggle.com/competitions/avazu-ctr-prediction/data> (дата обращения: 12.12.2025).
16. Яндекс Практикум. Основы работы с DataLens [Электронный ресурс]. 2026. URL: https://practicum.yandex.ru/ycloud-datalens/?from=profile_overview (дата обращения: 05.01.2026).
17. Prihatiningsih T., Panudju R., Prasetyo I.J. Digital Advertising Trends and Effectiveness in the Modern Era: A Systematic Literature Review // Golden Ratio of Marketing and Applied Psychology of Business. 2024. Т. 5, № 1. Сс. 1–12.
18. McMahan H.B. и др. Ad Click Prediction: a View from the Trenches // Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Chicago, Illinois, USA: ACM, 2013. Сс. 1222–1230.
19. Li L. Click-Through-Rate Prediction Using Deep Neural Networks and Efficient Channel Attention Mechanisms // Informatica. Slovenian Society Informatika, 2025. Т. 49, № 19. Сс. 21–36.
20. Jieming Z. и др. Open Benchmarking for Click-Through Rate Prediction // Proceedings of the 30th ACM International Conference on Information and Knowledge Management. Virtual Event, Queensland, Australia: ACM, 2021. Сс. 2759–2769.

21. Robertas D., Ligita Z.-J. Usability and Security Testing of Online Links: A Framework for Click-Through Rate Prediction Using Deep Learning // Electronics. MDPI, 2022. Т. 11. С. 400.
22. Kaggle. Avazu Click-Through Rate Prediction [Электронный ресурс]. 2026. URL: <https://www.kaggle.com/competitions/avazu-ctr-prediction/leaderboard> (дата обращения: 21.03.2026).